Propuesta de investigación

Maria Paula Camargo[*], Universidad Nacional de Colombia
Karen Barrantes[**], Universidad Nacional de Colombia

Resumen

En esta propuesta queremos estudiar si existe una asociación entre el consumo diario de cafeína y la prevalencia autorreportada de enfermedad cardiovascular (ECV) en adultos de Estados Unidos, usando los datos públicos de la encuesta NHANES 2017-2018. La idea es caracterizar a la población encuestada, describir cómo se comporta la prevalencia de ECV según el nivel de consumo de cafeína, y evaluar esa relación con modelos estadísticos que permitan controlar el efecto de la edad, el sexo y otras variables sociodemográficas, para saber si lo que se observa a simple vista se sostiene o si en realidad se explica por esos factores.

Índice

1. Problema de investigación **2**

1.1. Tema o título 2

1.2. Planteamiento del problema 3

1.3. Pregunta de investigación 3

2. Justificación **3**

3. Objetivos **4**

3.1. Objetivo general 4

3.2. Objetivos específicos 4

4. Antecedentes **5**

5. Marco conceptual **5**

[*] mcamargo@unal.edu.co
[**] kbarrantes@unal.edu.co

6. Metodología **6**
6.1. Enfoque y diseño de investigación 6
6.2. Población, unidad de análisis y muestra 7
6.2.1. Diseño muestral 7
6.3. Variables e indicadores 7
6.4. Fuentes de información e instrumentos 9
6.4.1. Fuentes 9
6.4.2. Instrumentos 9
6.5. Procedimiento 9
6.5.1. Integración de las bases de datos 9
6.5.2. Selección de la población estudio 9
6.5.3. Tratamiento de datos faltantes y estrategia de análisis 10
6.5.4. Valores atípicos y consistencia 10
6.5.5. Variables derivadas 11
6.6. Análisis descriptivo preliminar 11
6.7. Plan preliminar de análisis estadístico 13
6.8. Consideraciones éticas y manejo de la información 14

7. Resultados preliminares **14**

8. Cronograma **16**

9. Anexos **16**

10. Referencias **18**

1. Problema de investigación

1.1. Tema o título

Consumo de cafeína y enfermedad cardiovascular en adultos de Estados Unidos en un análisis de la encuesta NHANES 2017-2018.

1.2. Planteamiento del problema

El café es una de las bebidas más consumidas en el mundo, y durante años se discutió qué tanto afecta la salud del corazón, en parte porque la cafeína puede subir momentáneamente la presión arterial y el ritmo cardíaco. Sin embargo, los estudios que han seguido a grandes grupos de personas en el tiempo muestran un panorama distinto: un metaanálisis dosis-respuesta con 36 cohortes y más de 1,2 millones de participantes encontró que el riesgo no sube de forma lineal con el consumo, sino que es menor entre quienes toman 3 a 5 tazas al día (Ding et al. 2014); una revisión sombrilla de más de 200 metaanálisis llegó a conclusiones parecidas (Poole et al. 2017), y un análisis conjunto de las cohortes Framingham, ARIC y CHS asoció un mayor consumo de café con menor riesgo de falla cardíaca (Stevens et al. 2021). Estas tres fuentes son estudios de cohorte, es decir, siguen a las personas en el tiempo, lo que les permite hablar en términos de "riesgo"; nuestro estudio usará una fuente distinta.

Queremos mirar esta pregunta con la Encuesta Nacional de Salud y Nutrición de Estados Unidos (NHANES), pública, representativa a nivel nacional y que combina dieta con autorreporte de diagnósticos médicos (Centers for Disease Control and Prevention (CDC), National Center for Health Statistics 2018). Como NHANES recoge la cafeína y los antecedentes de enfermedad en el mismo momento, cualquier hallazgo de este estudio será una asociación transversal, no una estimación de riesgo ni evidencia de que la cafeína cause o prevenga la enfermedad. Además, tanto el consumo de cafeína como la ECV están asociados con la edad y el sexo, así que una relación que se vea "a simple vista" podría deberse a estos dos factores y no a un efecto propio de la cafeína. Por eso creemos que vale la pena revisar, con los datos de NHANES, si existe esa asociación una vez se controla por edad, sexo y otras características sociodemográficas (véase el diccionario de variables en el Anexo 1), dentro de los límites que impone un diseño observacional y transversal.

1.3. Pregunta de investigación

¿Existe asociación entre la ingesta diaria de cafeína y la prevalencia autorreportada de enfermedad cardiovascular en adultos de Estados Unidos (NHANES 2017-2018), una vez se tienen en cuenta la edad, el sexo y otras características sociodemográficas?

2. Justificación

Estudiar la cafeína y la enfermedad cardiovascular es relevante tanto para la salud pública como para la formación estadística. La cafeína la consume casi toda la población adulta y es fácil de modificar en la dieta; tener evidencia sobre si se asocia (o no) con la ECV aporta un insumo adicional a esa discusión, aunque un estudio transversal como este no puede, por sí solo, establecer límites de consumo seguro —eso requiere además evidencia longitudinal y, de ser posible, experimental.

Desde lo **estadístico**, trabajar con una base secundaria como NHANES permite describir una muestra, comparar grupos, evaluar si una asociación observada se debe en realidad a otras variables, y ajustar modelos que consideren varios factores a la vez; si el tiempo y los datos lo permiten, también da espacio para mirar si la relación es realmente lineal. Desde lo **práctico**, los resultados ayudarían a aclarar si el consumo habitual de cafeína se asocia con una mayor prevalencia autorreportada de ECV, o si esa asociación en realidad se explica por la edad y el sexo de quienes consumen más cafeína; por el carácter transversal del estudio, esto no permitiría afirmar que la cafeína es (o no) un factor de riesgo cardiovascular en sentido causal, pero sí aportaría evidencia descriptiva para contrastar con los estudios de cohorte disponibles.

Por último, el proyecto es un buen ejercicio de formación porque obliga a convertir una pregunta de salud pública en variables medibles a partir de datos reales, plantear hipótesis que se puedan poner a prueba y elegir herramientas estadísticas coherentes con datos transversales y con las limitaciones de un estudio observacional. En cuanto a viabilidad, los datos de NHANES son de acceso público y ya contamos con un primer acercamiento exploratorio a la base.

3. Objetivos

3.1. Objetivo general

Evaluar la asociación entre la ingesta diaria de cafeína y la prevalencia autorreportada de enfermedad cardiovascular en adultos de Estados Unidos, a partir de los datos de la encuesta NHANES 2017-2018, considerando el efecto de la edad, el sexo y otras características sociodemográficas.

3.2. Objetivos específicos

1. **Caracterizar** a los adultos de la muestra según variables sociodemográficas (edad, sexo, raza, nivel educativo, razón ingreso/pobreza), consumo de cafeína y prevalencia de enfermedad cardiovascular.

2. **Describir y comparar** la prevalencia de enfermedad cardiovascular según categorías de consumo de cafeína (0, 1-100, 101-200, 201-400 y más de 400 mg/día).

3. **Explorar descriptivamente** si la relación entre cafeína y ECV se mantiene al estratificar por grupos etarios y por sexo, como insumo previo para decidir si estas variables deben tratarse como posibles factores de confusión en los modelos del objetivo 4.

4. **Estimar, controlando por posibles factores de confusión**, la asociación entre el consumo de cafeína y la enfermedad cardiovascular mediante modelos de regresión logística que ajusten por edad, sexo, raza, nivel educativo, razón ingreso/pobreza y energía total consumida.

5. **Explorar si la relación entre cafeína y ECV es lineal** o presenta curvatura en niveles altos de consumo, mediante un término cuadrático que complemente los modelos de regresión de los objetivos anteriores.

6. **Revisar qué tan estables son los resultados**, comprobando si se mantienen al mirar por separado cada tipo de evento cardiovascular (enfermedad coronaria, infarto y accidente cerebrovascular).

4. Antecedentes

La evidencia más citada sobre cafeína y enfermedad cardiovascular viene de estudios de cohorte. Ding et al. (2014), en un metaanálisis dosis-respuesta con 36 cohortes y más de 1,2 millones de participantes, encontraron una relación en forma de "U": menor riesgo entre quienes tomaban 3 a 5 tazas de café al día que entre quienes no tomaban o tomaban cantidades muy altas. Poole et al. (2017), en una revisión sombrilla de más de 200 metaanálisis y 17 ensayos clínicos, reportaron que el consumo habitual de café se asocia más con beneficios que con daños para distintos desenlaces, incluidos los cardiovasculares, aunque advierten que buena parte de esa evidencia es observacional. Stevens et al. (2021), con datos armonizados de las cohortes Framingham, ARIC y CHS, asociaron un mayor consumo de café con menor riesgo de desarrollar falla cardíaca.

Los tres trabajos coinciden en no reportar un aumento del riesgo cardiovascular con el consumo habitual de cafeína, lo que contrasta con la idea más antigua de que la cafeína eleva ese riesgo. Pero también comparten limitaciones relevantes para nuestro estudio: son longitudinales, con cohortes concentradas en ciertas regiones o grupos de edad, con covariables de ajuste que no siempre coinciden entre sí ni son necesariamente generalizables a la población de Estados Unidos, y ninguno corresponde a un análisis transversal sobre una muestra representativa a nivel nacional como NHANES —que además mide la exposición de otra forma (recordatorio dietético de 24 horas) y el desenlace como prevalencia autorreportada en un momento dado, no como incidencia a lo largo del tiempo. Tampoco discuten de forma explícita el papel de la edad y el sexo como posibles factores de confusión, pese a que ambas variables están fuertemente asociadas tanto con la cafeína como con la ECV. Ese es el vacío que busca atender esta propuesta: usar una fuente transversal, pública y representativa a nivel nacional para describir la asociación entre cafeína y ECV autorreportada, y evaluar explícitamente si se mantiene al controlar por edad, sexo y otras características sociodemográficas. No buscamos replicar los hallazgos de cohorte —las fuentes de datos y los diseños no son comparables—, sino aportar evidencia complementaria desde un enfoque metodológico distinto.

5. Marco conceptual

Cafeína e ingesta dietética. La cafeína es un alcaloide estimulante presente de forma natural en el café, el té y otros alimentos, y es la sustancia psicoactiva de consumo legal

más extendida en el mundo. En NHANES se estima mediante un recordatorio dietético de 24 horas (`DR1TCAFF`, en mg/día); al ser un único día de recordatorio, esta medición refleja un consumo puntual y no necesariamente el patrón habitual del participante, lo que constituye una fuente de error de medición a tener en cuenta al interpretar los resultados (Moshfegh et al. 2008).

Enfermedad cardiovascular (ECV) autorreportada. La variable `ecv` no corresponde a un diagnóstico clínico verificado por el equipo investigador, sino a que el participante informe si un profesional de salud le dijo alguna vez que tiene enfermedad coronaria, que tuvo un infarto o que tuvo un accidente cerebrovascular. Esto es habitual en encuestas de salud, pero implica que `ecv` está sujeta a los sesgos propios del autorreporte —olvido, desconocimiento del diagnóstico o diferencias en el acceso a servicios de salud— (Okura et al. 2004), por lo que la prevalencia estimada debe entenderse como *autorreportada* y no necesariamente como prevalencia clínica real.

Asociación, confusión y causalidad en diseños transversales. Un estudio transversal observa la exposición (cafeína) y el desenlace (ECV autorreportada) en un mismo momento, sin seguimiento en el tiempo; esto permite estimar asociaciones, pero no establecer la secuencia temporal entre exposición y desenlace ni, por tanto, inferir causalidad (Hernán y Robins 2020). Una **variable de confusión** —como la edad o el sexo— está asociada simultáneamente con la exposición y con el desenlace, y puede generar o distorsionar una asociación aparente entre ambos sin que exista una relación causal directa. Controlar estadísticamente la confusión, mediante estratificación o modelos de regresión múltiple, permite ver si una asociación observada se mantiene, se atenúa o desaparece al considerar estas características, pero no reemplaza las condiciones necesarias para hablar de causalidad. Por esta razón, en este documento se usa siempre el término "asociación" y se evita llamar a la cafeína, en sentido causal, factor de riesgo o de protección frente a la ECV.

Diseño muestral complejo de encuestas. NHANES no selecciona a sus participantes mediante muestreo aleatorio simple, sino mediante un diseño probabilístico, estratificado y por conglomerados (véase Metodología), documentado en las guías analíticas oficiales de la encuesta (Centers for Disease Control and Prevention (CDC), National Center for Health Statistics 2022). Esto tiene dos implicaciones: cada participante debe analizarse con un peso muestral que permite proyectar los resultados a la población de Estados Unidos, y las observaciones de un mismo conglomerado no son independientes entre sí, lo que afecta el cálculo de los errores estándar. Ignorar estos elementos del diseño subestima los errores estándar y sobreestima la significancia de las asociaciones encontradas.

6. Metodología

6.1. Enfoque y diseño de investigación

La investigación tiene un enfoque cuantitativo: usa variables medibles y procedimientos estadísticos para evaluar la asociación entre la ingesta diaria de cafeína y la prevalencia autorreportada de ECV, incorporando edad, sexo y otras características sociodemográficas para

ajustar por posibles factores de confusión.

Es un estudio observacional, analítico, no experimental y transversal: no se interviene sobre la ingesta de cafeína ni se asignan exposiciones a los participantes, sino que se analizan datos ya recolectados por NHANES en el ciclo 2017–2018, correspondientes a un único momento en el tiempo. Esto permite evaluar la existencia y magnitud de una asociación entre las variables de interés, pero no establecer una relación temporal ni concluir causalidad —justo lo que exige la pregunta de investigación.

6.2. Población, unidad de análisis y muestra

La población objetivo de NHANES 2017–2018 es la población civil no institucionalizada de Estados Unidos, sobre la cual la encuesta recoge información demográfica, socioeconómica, nutricional y de salud mediante entrevistas, exámenes físicos y pruebas de laboratorio. La unidad de análisis es cada participante que cumpla los criterios de inclusión del estudio; como se trabaja con una base de datos pública ya existente (NCHS/CDC), no se realiza un nuevo proceso de selección muestral, sino que se usan los registros ya recolectados por la encuesta original.

6.2.1. Diseño muestral

NHANES usa un muestreo probabilístico, estratificado, por conglomerados y multietápico (condados, segmentos censales, viviendas y personas), con probabilidades desiguales de selección y sobremuestreo de ciertos grupos poblacionales, documentado en las guías analíticas oficiales de la encuesta (Centers for Disease Control and Prevention (CDC), National Center for Health Statistics 2022). Por eso el análisis debe incorporar los pesos muestrales y las variables de diseño: como la cafeína y la energía total provienen del recordatorio dietético, el peso que corresponde usar es el del día 1 de recordatorio (`WTDRD1`) y no el de entrevista (`WTINT2YR`) ni el del examen físico (`WTMEC2YR`); `SDMVSTRA` y `SDMVPSU` se usarán como estrato y conglomerado en un diseño de encuesta tipo `svydesign` en R, de modo que los errores estándar reflejen la falta de independencia entre observaciones de un mismo conglomerado.

Criterios de inclusión y exclusión. Se incluyen los participantes del ciclo 2017–2018 que cumplan los criterios de elegibilidad y dispongan de información válida en las variables requeridas; se excluyen los registros que no cumplan dichos criterios o que carezcan de información indispensable, de acuerdo con la estrategia definida para el manejo de datos faltantes.

Tamaño de muestra. No se calcula un tamaño nuevo, dado que se usa una base de datos existente; la muestra analítica queda determinada por los participantes del ciclo 2017–2018 que cumplan los criterios de inclusión y cuenten con la información necesaria.

6.3. Variables e indicadores

El Cuadro 1 resume la variable de respuesta, la explicativa principal y las variables de control consideradas en el estudio, con su definición operacional, tipo de escala y fuente de origen en

NHANES.

Cuadro 1: Definición y caracterización de las variables del estudio

Variable	**Papel en el estudio**	**Definición operacional**	**Tipo/escala**	**Fuente**
[ecv]	[Respuesta]	[Variable derivada de *acv, coronaria* e *infarto* (ver anexo 1), Se codifica como 1 si la persona reporta haber recibido al menos uno de los tres diagnósticos y como 0 si reporta no haber recibido ninguno.]	[Cualitativa, nominal, binaria]	[Derivada]
[cafeina_mg]	[explicativa]	[Cafeína total ingerida en el día (recordatorio 24h), mg/día, ”0 mg”, ”1-100 mg”, ”101-200 mg”, ”201-400 mg”, ”>400 mg”]	[Cualitativa, nominal]	[DR1TCAFF]
[sexo]	[control]	[Sexo, codificado como Hombre/Mujer]	[Cualitativa]	[RIAGENDR]
[raza]	[control]	[Raza y origen hispano, codificado como: Negro no hispano, Asiatico no hispano, Blanco no hispano, Otra Raza / multirracial, Mexicano-americano, otro hispano.]	[Cualitativa, nominal]	[RIDRETH3]
[educacion]	[control]	[Nivel educativo, codificado como: ”Menos de 9no grado, 9-11 grado (sin terminar), Bachiller / GED, Universidad incompleta / tecnico, Universitario o mas]	[Cualitativa, ordinal]	[DMDEDUC2]
[pir]	[control]	[Razón ingreso familiar / línea de pobreza]	[Cuantitativa]	[INDFMPIR]
[kcal]	[control]	[Energía total ingerida en el día, codificada como kcal/día]	[Cuantitativa]	[DR1TKCAL]

6.4. Fuentes de información e instrumentos

6.4.1. Fuentes

Los datos provienen de NHANES 2017–2018, encuesta del National Center for Health Statistics (NCHS), perteneciente a los Centers for Disease Control and Prevention (CDC), que caracteriza el estado de salud y nutrición de la población mediante entrevistas domiciliarias y evaluaciones en centros de examen móviles. Se usarán datos secundarios de acceso público, en particular el cuestionario de condiciones médicas (*Medical Conditions Questionnaire*), de donde se construye la variable derivada `ecv` a partir de los antecedentes de accidente cerebrovascular, enfermedad coronaria e infarto de miocardio. No se hará recolección primaria: el trabajo consiste en seleccionar las variables pertinentes, revisar códigos y valores faltantes, construir `ecv` y aplicar los criterios de inclusión, considerando el diseño muestral de NHANES cuando corresponda.

6.4.2. Instrumentos

La información proviene de tres instrumentos de NHANES, aplicados por personal entrenado del NCHS. El cuestionario sociodemográfico (*Demographics*) se administra mediante entrevista asistida por computador en el hogar y aporta edad, sexo, raza, nivel educativo y razón ingreso/pobreza. El recordatorio dietético de 24 horas (*Dietary Interview*) se aplica en el centro de examen móvil con el método automatizado *USDA Automated Multiple-Pass Method* (Moshfegh et al. 2008), y de ahí vienen la cafeína (`DR1TCAFF`), la energía total (`DR1TKCAL`) y el peso muestral asociado (`WTDRD1`). El cuestionario de condiciones médicas (*Medical Conditions Questionnaire*) aporta los antecedentes autorreportados usados para construir `ecv`. Son instrumentos ya estandarizados y validados por el NCHS; el papel del equipo investigador se limita a seleccionar, integrar y analizar las variables pertinentes.

6.5. Procedimiento

6.5.1. Integración de las bases de datos

Se usaron tres archivos de NHANES correspondientes al ciclo 2017–marzo de 2020 (*prepandemic*): `DEMO_J.xpt` (demografía), `DR1TOT_J.xpt` (ingesta dietética total, primer día) y `MCQ_J.xpt` (condiciones médicas), de los cuales se seleccionaron solo las variables de interés para el estudio. Las tres bases se integraron mediante el identificador único de cada participante (`SEQN`) con un *inner join*, conservando solo a quienes tenían información en las tres fuentes. El resultado fue una base consolidada de **8.366 registros**, punto de partida para la depuración posterior.

6.5.2. Selección de la población estudio

Se restringió la población analítica a participantes de 20 años o más, porque las preguntas del cuestionario de condiciones médicas usadas para construir la ECV se dirigen a ese grupo

etario. Tras este filtro, la base pasó de 8.366 a 5.265 registros.

6.5.3. Tratamiento de datos faltantes y estrategia de análisis

Se evaluaron los valores faltantes en cafeína (`DR1TCAFF`), energía (`DR1TKCAL`) y razón ingreso/pobreza (`INDFMPIR`): 523 participantes sin información dietaria y 697 sin PIR, con los faltantes de cafeína y energía coincidiendo en las mismas personas —provienen del mismo instrumento— y una superposición solo parcial con los de PIR. En total, 1.081 de los 5.265 participantes (20,5 %) presentaron algún faltante en estas variables; además, las respuestas no concluyentes de `DMDEDUC2` se trataron como faltantes, y un registro quedó sin información suficiente para `ecv`. Tras aplicar los criterios de inclusión y disponibilidad de información, la muestra analítica preliminar de casos completos quedó en **4.180 participantes**.

El análisis principal usará una estrategia de casos completos (*complete-case analysis*): la regresión logística incluirá solo a los participantes con información válida en el desenlace y en todas las covariables del modelo. Esto da una muestra analítica consistente para estimar los *odds ratios* ajustados, pero su validez depende de los supuestos sobre el mecanismo de ausencia (Little y Rubin 2020); no se asumirá que las estimaciones están libres de sesgo solo porque los faltantes se concentren en las covariables. Como diagnóstico, se compararon los casos completos e incompletos: edad media de 51,2 frente a 52,2 años, 51,4 % frente a 53,2 % de mujeres, y 10,4 % frente a 9,0 % de prevalencia de ECV —diferencias que describen a ambos grupos, pero no bastan para descartar sesgo por exclusión.

Como análisis de sensibilidad complementario, si los patrones de ausencia lo justifican, se generarán varias bases imputadas, se estimará la regresión logística en cada una y los resultados se combinarán mediante las reglas de Rubin (Little y Rubin 2020), considerando el diseño muestral de NHANES. Comparar estos resultados con los del análisis de casos completos permitirá valorar si las conclusiones dependen de la estrategia usada para tratar los faltantes.

6.5.4. Valores atípicos y consistencia

Para los valores atípicos se revisarán la distribución, los rangos y los valores extremos de cafeína, energía y edad, con resúmenes estadísticos e histogramas o diagramas de caja; no se eliminarán automáticamente, dado que pueden corresponder a consumos reales, salvo que haya evidencia de error de registro, inconsistencia con la documentación de la encuesta o una justificación metodológica explícita. La consistencia se verificará revisando los códigos válidos, los registros duplicados, los rangos esperados y posibles contradicciones entre las condiciones médicas, además de comprobar que las variables derivadas sean coherentes con sus componentes originales y que los faltantes se propaguen adecuadamente cuando no haya información suficiente.

Cuadro 2: Distribución sociodemográfica y de consumo de cafeína (n = 4.180, sin ponderar)

Caracteristica	Porcentaje
Sexo: Mujer	51.4
Sexo: Hombre	48.6
Grupo de edad: 20-39	30.4
Grupo de edad: 40-59	31.7
Grupo de edad: 60+	37.9
Cafeina: 0 mg	15.0
Cafeina: 1-100 mg	34.4
Cafeina: 101-200 mg	24.5
Cafeina: 201-400 mg	19.5
Cafeina: >400 mg	6.6

6.5.5. Variables derivadas

La variable `ecv` se definió como binaria: toma el valor de uno si el participante reporta al menos una de las siguientes condiciones —enfermedad coronaria, infarto o accidente cerebrovascular— y cero si las tres respuestas indican ausencia; si no hay información suficiente, el desenlace se conserva como faltante. La ingesta de cafeína se agrupó en 0, 1-100, 101-200, 201-400 y más de 400 mg/día, y la edad en 20-39, 40-59 y 60 años o más, para describir la exposición y las características de los participantes; se conservan también las versiones continuas de estas variables para los análisis que las usen como tales.

6.6. Análisis descriptivo preliminar

Como avance del proyecto, presentamos una caracterización descriptiva preliminar de la muestra de casos completos (n = 4.180), siguiendo el procedimiento anterior. Corresponde a una primera aproximación a los objetivos 1 y 2. Estas cifras **no están ponderadas** por el diseño muestral de NHANES (no incorporan `peso_dieta`, `estrato` ni `psu`); son solo exploratorias, para verificar que la base se comporta de forma razonable antes de pasar a las estimaciones ponderadas y ajustadas del plan de análisis, y no deben leerse como representativas de la población de Estados Unidos.

Según el Cuadro 2, la muestra tiene una edad media de 51,2 años (rango 20-80), 51,4 % de mujeres y una prevalencia cruda de ECV de 10,4 %. Por categoría de cafeína (Cuadro 3):

La prevalencia cruda de ECV sube de forma aproximadamente monótona con la categoría de cafeína (9,3 % en “0 mg” a 16,1 % en “>400 mg”), pero la edad media también sube en el mismo sentido (de 46,7 a 53,9 años), y la prevalencia varía mucho más con la edad (1,2 % en 20-39 años frente a 21,1 % en 60 años o más, ver Figura 1) que con la cafeína. Este es justo el patrón de confusión anticipado en el planteamiento del problema y en el marco conceptual: quienes consumen más cafeína tienden a ser, en promedio, un poco mayores, y la edad está fuertemente asociada con la ECV. Por tanto, **no debe leerse como evidencia de que la**

Cuadro 3: Prevalencia de ECV y edad media por categoría de cafeína (sin ponderar, sin ajustar)

Categoría de cafeína	Prevalencia de ECV (%)	Edad media (años)
0 mg	9.3	46.7
1-100 mg	9.2	50.6
101-200 mg	10.4	51.7
201-400 mg	11.6	54.3
>400 mg	16.1	53.9

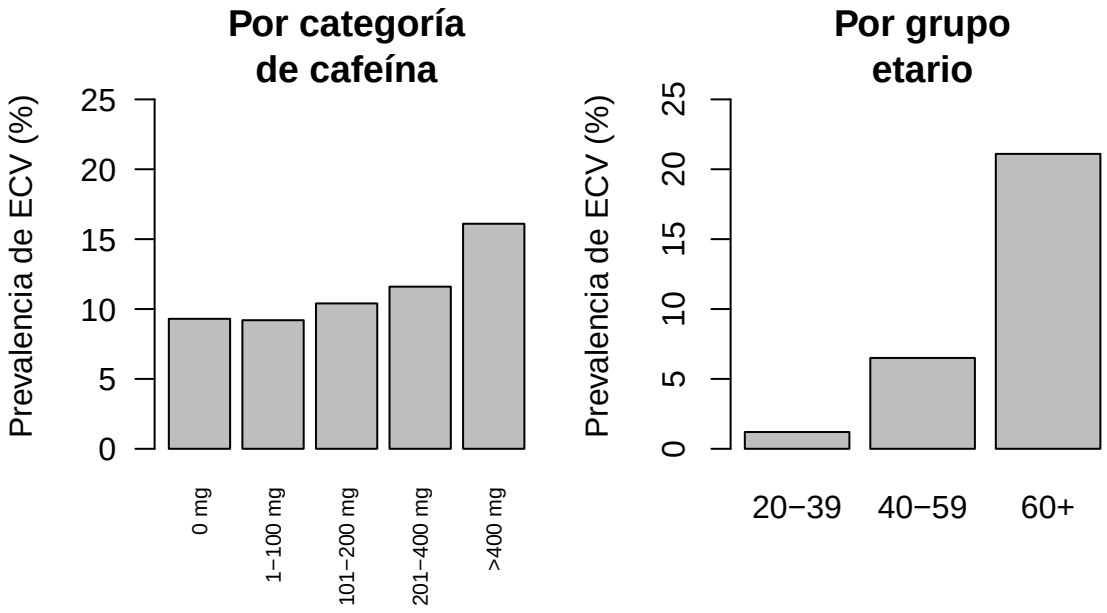


Figura 1: Prevalencia descriptiva (sin ponderar) de ECV autorreportada por categoría de cafeína y por grupo etario.

cafeína aumenta el riesgo cardiovascular; es precisamente la motivación de los análisis estratificados y ajustados de los objetivos 3 y 4.

6.7. Plan preliminar de análisis estadístico

Objetivo específico	Variables involucradas	Procedimiento estadístico propuesto
1	Edad, sexo, raza/etnia, nivel educativo, razón ingreso/pobreza, consumo de cafeína y ECV.	Análisis descriptivo de la población analítica: frecuencias y porcentajes para las variables categóricas, medidas de tendencia central y dispersión para las cuantitativas, incorporando los pesos y el diseño muestral de NHANES.
2	ECV (variable dicotómica) y consumo de cafeína.	Prevalencia de ECV por categoría de cafeína con intervalos de confianza del 95 %, comparadas con una prueba de asociación ajustada por diseño muestral complejo (Rao–Scott) (Rao y Scott 1984), sin asumir que las diferencias se deban solo a la cafeína.
3	Consumo de cafeína, ECV, edad y sexo.	Prevalencia de ECV por categoría de cafeína dentro de cada grupo etario (20–39, 40–59, 60+) y por sexo, de forma puramente descriptiva, para decidir si edad y sexo deben entrar como variables de control —y posibles interacciones— en el modelo del objetivo 4.
4	ECV, consumo de cafeína, edad, sexo, raza/etnia, nivel educativo, razón ingreso/pobreza y energía total consumida.	Regresión logística para encuestas complejas, con ECV como desenlace y cafeína como explicativa principal, ajustando por las covariables identificadas en el objetivo 3. Se reportarán OR ajustadas con IC 95 % y, si el objetivo 3 lo sugiere, se probarán interacciones cafeína×edad y cafeína×sexo. La interpretación será siempre como asociación, no como efecto causal.

Objetivo específico	Variables involucradas	Procedimiento estadístico propuesto
5	Consumo de cafeína en mg/día y ECV, con las mismas covariables del objetivo 4.	Al modelo del objetivo 4 se le agrega un término cuadrático de cafeína; su significancia se evalúa con una prueba de Wald ajustada por diseño. Un coeficiente significativo sugiere curvatura (forma de "U" o "J"); uno no significativo es consistente con una relación aproximadamente lineal.
6	Consumo de cafeína y cada evento cardiovascular por separado: coronaria (MCQ160C), infarto (MCQ160E) y accidente cerebrovascular (MCQ160F).	Análisis de sensibilidad: se repite el modelo del objetivo 4 por separado para cada evento cardiovascular, y se comparan las OR ajustadas entre sí y con el resultado principal, para ver si la asociación es consistente según el tipo de evento.

6.8. Consideraciones éticas y manejo de la información

El estudio usa información secundaria de NHANES 2017-2018 (NCHS/CDC), por lo que no implica reclutamiento de participantes ni recolección directa de datos. El consentimiento informado corresponde al proceso original de la encuesta; no se solicitará uno nuevo. Se trabajará con la base pública, ya desidentificada y sin identificadores personales directos, y los resultados se presentarán de forma agregada, evitando cualquier intento de reidentificación.

Los archivos se manejarán en un entorno de acceso controlado, conservando solo las variables necesarias para los objetivos del estudio, sin vincularlas con fuentes externas. El análisis seguirá los lineamientos de uso de datos públicos de NHANES, reconociendo la fuente original, y las conclusiones respetarán las limitaciones del diseño observacional y transversal: las asociaciones entre cafeína y ECV no se interpretarán como evidencia de causalidad. Al ser un análisis secundario de datos públicos desidentificados, no se prevé contacto con participantes ni recolección de información identificable; los requisitos institucionales de revisión ética aplicables deberán verificarse según las normas de la universidad.

7. Resultados preliminares

En el análisis ponderado según el diseño muestral de NHANES se identificó una muestra sociodemográficamente equilibrada entre sexos, con predominio de participantes blancos no hispanos y un nivel educativo relativamente alto, además de un consumo de cafeína extendido en casi toda la población adulta. A continuación se presentan los resultados esenciales de esta caracterización;

Cuadro 4: Características sociodemográficas y consumo de cafeína (ponderado, n = 4.180)

Variable	Categoría	Porcentaje (%)
sexo	Hombre	48.3
sexo	Mujer	51.7
raza	Asiatico no hispano	5.7
raza	Blanco no hispano	63.5
raza	Mexicano-americano	8.7
raza	Negro no hispano	10.9
raza	Otra raza / multirracial	4.9
raza	Otro hispano	6.4
educacion	Menos de 9no grado	3.0
educacion	9-11 grado (sin terminar)	7.3
educacion	Bachiller / GED	28.4
educacion	Universidad incompleta / tecnico	31.3
educacion	Universitario o mas	30.0
cat_cafeina	0 mg	11.9
cat_cafeina	1-100 mg	29.2
cat_cafeina	101-200 mg	25.4
cat_cafeina	201-400 mg	25.0
cat_cafeina	>400 mg	8.4

Cuadro 5: Variables cuantitativas (ponderadas, n = 4.180)

Variable	Media	Mediana	RIC (p25-p75)
edad	48.3	48.0	33 - 62
pir	3.1	3.1	1.5 - 5
kcal	2159.1	1994.0	1468 - 2667
cafeina_mg	173.1	131.0	33 - 247

Como se evidencia en el Cuadro 4, la muestra queda prácticamente dividida en partes iguales entre mujeres (51,7 %) y hombres (48,3 %); el 63,5 % se identifica como blanco no hispano, seguido de negro no hispano (10,9 %) y mexicano-americano (8,7 %); y en cuanto a cafeína, solo el 11,9 % reporta no consumir nada, mientras que el consumo moderado de 1 a 100 mg/día es la categoría más frecuente (29,2 %).

En las variables cuantitativas (Cuadro 5) se identificó una edad mediana de 48 años (la mitad de los adultos tiene entre 33 y 62 años), un ingreso familiar relativo a la línea de pobreza (PIR) mediano de 3,1, y un consumo mediano de cafeína de 131 mg/día, con bastante dispersión entre personas (RIC de 33 a 247 mg).

El hallazgo más relevante de este primer corte se identificó al comparar la prevalencia de ECV ponderada con la estimación cruda; como se evidencia en la Figura 2, la prevalencia sin ponderar (10,4 %) sobreestima la prevalencia ponderada (7,9 %; IC 95 %: 6,2-9,9 %) en más de dos puntos porcentuales. Esto confirma que ignorar los pesos y el diseño muestral de

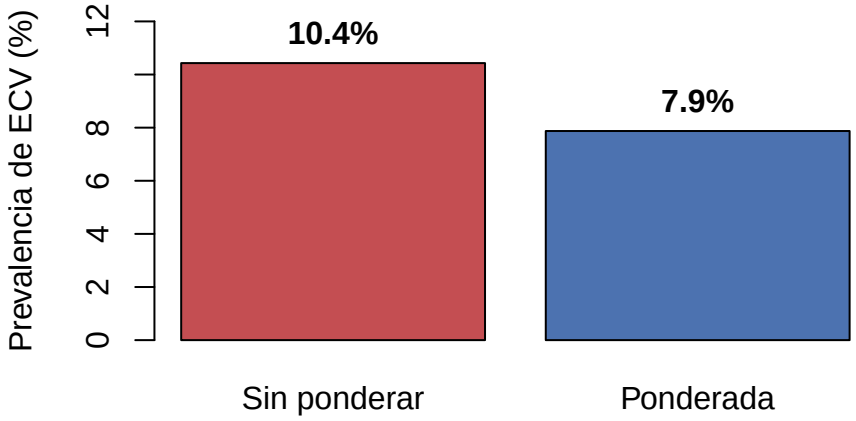


Figura 2: Prevalencia de ECV autorreportada: estimación ponderada (diseño muestral de NHANES) frente a la estimación sin ponderar.

NHANES lleva a una prevalencia que no representa bien a la población de Estados Unidos. Las demás características (sexo, raza, educación, PIR, consumo de cafeína) no cambiaron tanto entre la versión ponderada y la exploración sin ponderar del avance, lo cual tiene sentido porque la ECV está concentrada en los grupos de mayor edad, que es justo donde más pesa el sobremuestreo de NHANES.

8. Cronograma

Actividad	Período 1	Período 2	Período 3	Período 4
Revisión bibliográfica	X	X		
Obtención y preparación de datos		X	X	
Análisis estadístico			X	X
Elaboración del informe final				X

9. Anexos

Anexo 1. Diccionario de variables de la base analítica.

Variable	Origen (NHANES)	Descripción	Codificación
`edad`	RIDAGEYR	Edad al momento del examen	Años (80 = 80 o más)
`sexo`	RIAGENDR	Sexo	Hombre / Mujer
`raza`	RIDRETH3	Raza y origen hispano	6 grupos
`educacion`	DMDEDUC2	Nivel educativo	5 niveles
`pir`	INDFMPIR	Razón ingreso familiar / línea de pobreza	0-5
`cafeina_mg`	DR1TCAFF	Cafeína total ingerida en el día (recordatorio 24h)	mg/día
`kcal`	DR1TKCAL	Energía total ingerida en el día	kcal/día
`peso_dieta`	WTDRD1	Peso muestral del recordatorio dietario (día 1)	Numérico
`estrato`	SDMVSTRA	Estrato de muestreo para análisis de diseño complejo	Numérico
`psu`	SDMVPSU	Unidad primaria de muestreo para análisis de diseño complejo	Numérico
`coronaria`	MCQ160C	Diagnóstico autorreportado de enfermedad coronaria	1 = sí, 0 = no
`infarto`	MCQ160E	Diagnóstico autorreportado de infarto	1 = sí, 0 = no
`acv`	MCQ160F	Diagnóstico autorreportado de ACV	1 = sí, 0 = no
`ecv`	derivada	Al menos uno de los tres diagnósticos anteriores	1 = sí, 0 = no
`cat_cafeina`	derivada	Categoría de consumo de cafeína	5 niveles
`grupo_edad`	derivada	Grupo etario	20-39, 40-59, 60+

10. Referencias

Centers for Disease Control and Prevention (CDC), National Center for Health Statistics. 2018. *National Health and Nutrition Examination Survey Data 2017–2018*. U.S. Department of Health; Human Services.

Centers for Disease Control and Prevention (CDC), National Center for Health Statistics. 2022. *National Health and Nutrition Examination Survey: Analytic Guidelines*. U.S. Department of Health; Human Services.

Ding, Ming, Shilpa N. Bhupathiraju, Ambika Satija, Rob M. van Dam, y Frank B. Hu. 2014. «Long-term coffee consumption and risk of cardiovascular disease: a systematic review and a dose-response meta-analysis of prospective cohort studies». *Circulation* 129 (6): 643-59.

Hernán, Miguel A., y James M. Robins. 2020. *Causal Inference: What If*. Chapman & Hall/CRC.

Little, Roderick J. A., y Donald B. Rubin. 2020. *Statistical Analysis with Missing Data*. 3rd ed. Wiley Series en Probability y Statistics. John Wiley & Sons. https://doi.org/10.1002/9781119482260.

Moshfegh, Alanna J., Donna G. Rhodes, David J. Baer, et al. 2008. «The US Department of Agriculture Automated Multiple-Pass Method reduces bias in the collection of energy intakes». *The American Journal of Clinical Nutrition* 88 (2): 324-32.

Okura, Yukari, Lenore H. Urban, Daniel W. Mahoney, Steven J. Jacobsen, y Richard J. Rodeheffer. 2004. «Agreement between self-report questionnaires and medical record data was substantial for diabetes, hypertension, myocardial infarction and stroke but not for heart failure». *Journal of Clinical Epidemiology* 57 (10): 1096-103.

Poole, Robin, Oliver J. Kennedy, Paul Roderick, Jonathan A. Fallowfield, Peter C. Hayes, y Julie Parkes. 2017. «Coffee consumption and health: umbrella review of meta-analyses of multiple health outcomes». *BMJ* 359: j5024.

Rao, J. N. K., y A. J. Scott. 1984. «On Chi-Squared Tests for Multiway Contingency Tables with Cell Proportions Estimated from Survey Data». *The Annals of Statistics* 12 (1): 46-60.

Stevens, Laura M., Erin Linstead, Jennifer L. Hall, y David P. Kao. 2021. «Association between coffee intake and incident heart failure risk: a machine learning analysis of the FHS, the ARIC Study, and the CHS». *Circulation: Heart Failure* 14 (2): e006799.